


طراحی و تحلیل عامل هوشمند در هزارتوی پویا

گزارش کامل پروژه پایانی درس یادگیری تقویتی



نام و نام خانوادگی: امیرحسین درهمی

شماره دانشجویی: 40406934

سید (seed) پروژه: 3

اندازه نقشه: 18 x 18

استاد درس: دکتر خواسته

تابستان 1405

فهرست تصاویر

- ۱.۳ نرخ خاتمه‌آپزود با سیاست تصادفی و نرخ موفقیت سیاست بهینه VI در برابر بودجه انرژی. سیاست بهینه در همه بودجه‌ها موفقیت 1.0 دارد، اما سیاست تصادفی تقریباً همیشه با اتمام انرژی خاتمه می‌یابد – نشان می‌دهد محدودیت انرژی برای یک عامل نیاموخته واقعاً سخت‌گیرانه است. ۹
- ۱.۴ همگرایی Value Iteration برای سه مقدار γ . با افزایش γ افق مؤثر بلندتر می‌شود و همگرایی کندتر رخ می‌دهد (حدود 83 تکرار برای $\gamma=0.9$ در برابر حدود 101 تکرار برای $\gamma=0.99$). ۱۰
- ۲.۴ تعداد تکرار تا همگرایی و زمان اجرا با افزایش γ رشد آهسته‌ای دارند، اما نرخ موفقیت سیاست حریصانه در هر سه مقدار γ برابر 1.0 است – یعنی γ عمدتاً مقیاس V را تغییر می‌دهد، نه خود سیاست بهینه نهایی. ۱۱
- ۳.۴ نقشه حرارتی V و فلش سیاست حریصانه Value Iteration پیش و پس از دریافت کلید ($k=0$) در برابر ($k=1$). سیاست VI به‌عنوان مرجع مقایسه برای دو الگوریتم مدل‌آزاد استفاده می‌شود. ۱۱
- ۱.۵ نقشه بازدید Q-Learning (پاداش شکل‌دهی‌شده، برنامه‌نمایی) پیش و پس از دریافت کلید. پیش از کلید، بازده‌ها به‌شدت روی مسیر کوتاه به سمت کلید متمرکز است (نوار زرد پررنگ)؛ پس از دریافت کلید، بازده‌ها روی چند مسیر جایگزین به سمت هدف پخش می‌شود. ۱۲
- ۲.۵ مسیر نهایی حریصانه Q-Learning (پاداش شکل‌دهی‌شده، برنامه‌نمایی) از شروع تا هدف در 71 گام، با پایان موفق (term=goal_reached). ۱۳
- ۳.۵ مقایسه منحنی پاداش/تعداد گام بین حالت sparse و shaped (برنامه‌نمایی)، میانگین $\pm$ انحراف معیار سه سید. منحنی shaped بالاتر و پایدارتر از sparse است و به سیاست نهایی قوی‌تری می‌رسد (نرخ موفقیت ارزیابی 0.99 در برابر 0.49). ۱۴
- ۴.۵ مقایسه برنامه کاهش ϵ (خطی در برابر نمایی) برای پاداش sparse. برنامه‌نمایی نخستین موفقیت را زودتر ثبت می‌کند، اما برنامه خطی به سیاست نهایی قوی‌تری می‌رسد (میانگین موفقیت ارزیابی 0.58 در برابر 0.49). ۱۴

- ۱.۶ چپ: خطای TD (δ) طی یک اپیزود نمونه (اپیزود 10). راست: افت نمایی ردپای شایستگی (E)، مقیاس لگاریتمی) برای چند زوج حالت-عمل؛ نقاط اوج مجدد نشان‌دهنده بازدید دوباره همان زوج و بازنشانی شایستگی (رفتار replacing) است. ۱۶
- ۲.۶ نقشه بازدید SARSA($\lambda=0$) (پاداش شکل‌دهی‌شده) پیش و پس از کلید. در مقایسه با Q-Learning (شکل ۱.۵) پراکندگی بازدهها بیشتر و کمتر متمرکز روی یک مسیر باریک است – سازگار با رفتار محتاطانه‌تر on-policy در برابر ریسک اکتشاف. ۱۷
- ۳.۶ مقایسه نرخ پاداش/گام برای SARSA($\lambda=0.3$): sparse در برابر shaped (پس از اصلاح شبکه آزمایش). ۱۷
- ۴.۶ جاروب λ برای پاداش sparse (سه سید). پایداری اواخر آموزش تقریباً مستقل از λ است (انحراف معیار بازگشت در 1000 اپیزود آخر: 155.2، 156.5، 157.2، 156.8 برای $\lambda=0, 0.3, 0.7, 0.9$) و نرخ موفقیت ارزیابی برای هر چهار مقدار برابر صفر است – نتیجه مدل‌های کوتاه 50-اپیزودی (dry-run) نه شکست خود ردپای شایستگی. ۱۸
- ۱.۷ سیاست آموخته‌شده هر الگوریتم (فلش = عمل حریصانه، رنگ = مقدار $\max-Q/V$ خود الگوریتم در پرتکرارترین سطح انرژی بازدیدشده). سیاست Value Iteration هر خانه معتبر را پوشش می‌دهد؛ Q-Learning تقریباً تمام حالت‌های معتبر را (264/266 در حالت دارای کلید) پوشش داده، اما SARSA پوشش کمتری دارد (173–230/266 بسته به مدل/سید) که با ماهیت محتاطانه‌تر اکتشاف on-policy سازگار است. ۲۱
- ۲.۷ درصد توافق عمل حریصانه SARSA/Q-Learning با سیاست مرجع Value Iteration در هر خانه (سبز = همیشه هم‌راستا، قرمز = هرگز هم‌راستا). در میان حالت‌های بازدیدشده، نرخ توافق عمل با VI برای Q-Learning $\approx 32.2\%$ و برای SARSA $\approx 21.9\%$ است (comparison_summary.csv). Q-Learning به‌طور کلی توافق بالاتر و یکنواخت‌تری نسبت به SARSA نشان می‌دهد؛ خانه‌های سفید یعنی آن حالت اصلاً بازدید نشده است. ۲۲
- ۱.۸ مسیر حریصانه در نقشه مبدأ (72 گام) در برابر نقشه مقصد مشابه پس از انتقال کامل (60 گام) – انتقال روی هدف مشترک به مسیری کوتاه‌تر رسیده است. ۲۴
- ۲.۸ مسیر حریصانه در نقشه مبدأ (72 گام) در برابر نقشه مقصد متفاوت پس از انتقال کامل (68 گام). با وجود جابه‌جایی هدف/موانع، عامل همچنان به هدف رسیده است، اما مسیر آموخته‌شده حلقه‌های اضافی (دور زدن‌های تکراری نزدیک کلید) دارد که نشانه سازگاری ناقص دانش منتقل‌شده با ساختار جدید است. ۲۵
- ۳.۸ عملکرد آموزش روی نقشه مشابه: تمام سناریوهای انتقال (full, scaled_0.25/0.5/0.75) بازگشت شروع (jumpstart) نزدیک به صفر دارند در برابر حدود 1330- برای آموزش از صفر و حدود 1020- برای انتقال انتخابی – انتقال کامل بهترین شروع را می‌دهد و منحنی یادگیری عملاً از همان ابتدا نزدیک به سیاست همگراست. ۲۵

- ۴.۸ عملکرد آموزش روی نقشه متفاوت: مزیت انتقال بسیار کوچکتر است (jumpstart حدود 1100- تا 1200- برای scaled/full در برابر حدود 1400- برای آموزش از صفر) و جالب اینکه انتقال انتخابی (حدود 1360-) عملاً هیچ مزیت معناداری نسبت به آموزش از صفر ندارد – چون معیار «همسایگی محلی بدون تغییر» وقتی $+35\%$ نقشه عوض شده، تعداد بسیار کمی حالت را واجد شرایط انتقال می‌کند. ۲۶
- ۵.۸ اختلاف قدر مطلق max-Q پیش و پس از انتقال (مبدأ شکل‌دهی شده $\rightarrow$ مقصد متفاوت/کامل)، در سطح انرژی حداکثر. در حالت بدون کلید (چپ) تغییرات تقریباً ناچیز و پراکنده‌اند؛ اما در حالت دارای کلید (راست) تقریباً کل نقشه اختلاف کوچک ولی سیستماتیک نشان می‌دهد – سازگار با این واقعیت که هدف/کلید در نقشه متفاوت جابه‌جا شده و بنابراین دقیقاً بخش پس‌از-کلید سیاست است که باید بازآموزی شود. ۲۶
- ۱.۹ رابط گرافیکی در حین ارزیابی سیاست VI. ۲۹
- ۲.۹ نمایش روی هم‌گذاری سیاست VI روی نقشه (پوشش سیاست برش $has_key=1$). ۲۹
- ۳.۹ رابط گرافیکی در حین ارزیابی Q-Learning. ۳۰
- ۴.۹ رابط گرافیکی در حین ارزیابی SARSA. ۳۰

فهرست جداول

- ۱.۳ جاروب بودجه انرژی ثبت شده در `results/raw_data/energy/energy_sweep.csv`: رفتار سیاست تصادفی و عملکرد سیاست بهینه VI در هر بودجه. سیاست بهینه در همه بودجه ها موفقیت 1.0 دارد، اما سیاست تصادفی تقریباً همیشه با اتمام انرژی خاتمه می یابد. ۸
- ۱.۵ موفقیت ارزیابی (گشوده حریصانه، 100 اپیزود) برای هر ترکیب پاداش/برنامه. شکل دهی پاداش تأثیر بسیار بزرگی بر کیفیت سیاست نهایی دارد. ۱۴
- ۱.۷ جدول مقایسه سه الگوریتم. *مقادیر SARSA/Q-Learning در `reference_reward_mode=sparse` و پس از اصلاح باگ انتخاب بهترین مدل (منبع: `comparison_summary.csv`، `eval_saved_models_summary.csv`). برای Q-Learning بهترین ترکیب (برنامه خطی) میانگین سه سید $0.58 = \frac{0.59+0.51+0.64}{3}$ داده است؛ مقدار SARSA مربوط به مدل های کوتاه 50-اپیزودی (dry-run) است و صفر آن به معنای اثبات شکست الگوریتم نیست. ۲۰
- ۱.۱۱ جدول کوتاه افشای استفاده از هوش مصنوعی (نسخه کامل در `README.md` مخزن پروژه موجود است). ۳۵

فصل ۱

خلاصه پروژه

این پروژه یک هزارتوی پویا و تصادفی با ابعاد 18×18 پیاده‌سازی می‌کند که در آن عامل باید به ترتیب: ابتدا کلید را جمع‌آوری کند، سپس از یک در بسته عبور کند و در نهایت به خانه هدف برسد. محیط با احتمال 0.8 عمل انتخابی عامل را اجرا می‌کند و با احتمال 0.1 به هر یک از دو جهت عمود منحرف می‌شود؛ برخورد با دیوار عامل را در جای خود نگه می‌دارد و جریمه اعمال می‌کند. قابلیت تکمیلی انتخاب‌شده برای این پروژه **انرژی محدود** است: هر گام یک واحد از انرژی عامل کم می‌شود و پایان یافتن انرژی، اپیزود را با شکست خاتمه می‌دهد؛ بنابراین انرژی باقی‌مانده بخشی جدانشدنی از حالت عامل است.

سه الگوریتم Value Iteration، Q-Learning و $SARSA(\lambda)$ از پایه (بدون استفاده از کتابخانه‌های آماده یادگیری تقویتی) پیاده‌سازی و روی دقیقاً یک نقشه و یک تعریف پاداش یکسان مقایسه شده‌اند. علاوه بر این، یک مطالعه محدود انتقال یادگیری روی Q-Learning با دو نقشه مقصد (مشابه و متفاوت) انجام شده است. یک رابط گرافیکی مستقل نیز حرکت عامل و سیاست آموخته‌شده را به‌صورت زنده نمایش می‌دهد.

مقدار پایه seed و اندازه نقشه بر اساس شماره دانشجویی محاسبه شده‌اند:

$$b = \text{int}(\text{StudentID}[-2]) = 3, \quad N = 15 + (b \bmod 4) = 18$$

فصل ۲

تعریف محیط و مدل سازی MDP

۱.۲ تعریف حالت و حفظ خاصیت مارکوف

از آنجا که باز یا بسته بودن در به دریافت کلید وابسته است و افق باقی مانده اپیزود به انرژی وابسته است، حالت تنها مختصات مکانی نیست. حالت به صورت زیر تعریف شده است:

$$s = (r, c, \text{has_key}, \text{energy})$$

با دانستن این چهار مقدار و عمل انتخاب شده، توزیع احتمال حالت بعدی کاملاً مشخص است و نیازی به تاریخچه گام های قبلی نیست؛ بنابراین خاصیت مارکوف حفظ می شود. جزئیات پیاده سازی در `environments/maze.py` تابع `all_states/encode_state` است.

۲.۲ فضای عمل و مدل انتقال

فضای عمل شامل چهار عمل {بالا، پایین، چپ، راست} است. با احتمال `p_intended=0.8` عمل انتخابی اجرا و با احتمال `p_perp=0.1` برای هر یک از دو جهت عمود، عامل منحرف می شود. برخورد با دیوار یا مرز نقشه، عامل را در حالت فعلی نگه می دارد و جریمه `wall_hit` اعمال می شود. تلاش برای عبور از در بدون کلید نیز عامل را در جای خود نگه داشته و جریمه `door_attempt` اعمال می کند. در هر گام، صرف نظر از نتیجه حرکت، یک واحد از انرژی کاسته می شود.

۳.۲ توابع پاداش: نسخه sparse و shaped

دو نسخه از تابع پاداش در `experiments/configs/default\_config.json` تعریف شده اند:

- **sparse**: بلوک `rewards` – پاداش عمده فقط هنگام دریافت کلید یا رسیدن به هدف، به همراه هزینه کوچک هر حرکت و جریمه برخورد با دیوار/جریمه/تلاش نافرجام برای در.

• **shaped**: بلوک shaping – بازخورد شکل‌دهی شده مبتنی بر پتانسیل برای نزدیک شدن به کلید/هدف، پاداش سقف‌دار برای عبور ایمن از نزدیکی خانه‌های جریمه، و جریمه حرکت اتلافی.

مقادیر عددی پاداش‌ها از experiments/configs/default_config.json: step: -1, wall_hit: -5, penalty_cell: -10, key: +50, door_attempt: -5, goal: +200, gamma_shaping: 0.95, dis-؛ پارامترهای شکل‌دهی: tance_shaping_scale: 1.0, safe_distance_cap: 3, safe_passage_scale: 0.5, wasted_move_penalty: -3.

نتیجه کلی مشاهده شده در این پروژه این است که شکل‌دهی پاداش صرفاً سرعت آموزش را افزایش نداده، بلکه کیفیت سیاست نهایی Q-Learning را نیز به‌طور محسوس بهبود داده است: نرخ موفقیت ارزیابی میانگین سه سید از حدود 0.58 (پاداش sparse، برنامه خطی) به حدود 0.99 (پاداش shaped، برنامه خطی) با بودجه انرژی 500 و 20000 اپیزود رسیده است (ر.ک. فصل Q-Learning و results/raw_data/eval_saved_models_summary.csv).

۴.۲ سقف اپیزود و شرایط پایان

هر اپیزود با یکی از این سه حالت پایان می‌یابد: رسیدن عامل به هدف با کلید، اتمام انرژی، یا عبور تعداد گام‌ها از سقف تعیین شده (عبور قابل‌خنده‌ای تعداد $\times 3$ ؛ پارامتر env.max_steps_multiplier).


فصل ۳

انتخاب بودجه انرژی (قابلیت تکمیلی)

پیش از آموزش کامل، یک بررسی (energy sweep) روی مقادیر مختلف max_energy انجام شد تا مشخص شود کدام بودجه انرژی همزمان از دید سیاست بهینه VI قابل حل است و به یادگیرنده‌های مدل آزاد شانس واقعی برای موفقیت می‌دهد. داده‌های ثبت شده در results/raw_data/energy/energy_sweep.csv برای هر بودجه شامل اندازه فضای حالت، رفتار یک سیاست تصادفی، و نرخ موفقیت سیاست بهینه VI است:

max_energy	تعداد حالت	خاتمه با اتمام انرژی (تصادفی)	موفقیت (تصادفی)	موفقیت VI	تکرار VI	زمان VI (ثانیه)
۶۰	۳۹,۵۲۸	۰۰.۱	۰۰.۰	۰.۱	۶۱	۰.۸۷
۱۰۰	۶۵,۴۴۸	۰۰.۱	۰۰.۰	۰.۱	۹۲	۲.۲۱۲
۱۵۰	۹۷,۸۴۸	۰۰.۱	۰۰.۰	۰.۱	۹۲	۴.۳۴۵
۲۰۰	۱۳۰,۲۴۸	۹۹۵.۰	۰۰۵.۰	۰.۱	۹۲	۲.۳۴۱
۳۰۰	۱۹۵,۰۴۸	۹۷۵.۰	۰۲۵.۰	۰.۱	۹۲	۴.۵۸۱
۴۰۰	۲۵۹,۸۴۸	۹۷۵.۰	۰۲۵.۰	۰.۱	۹۲	۱.۶۱۴
۵۰۰	۳۲۴,۶۴۸	۹۷.۰	۰۳.۰	۰.۱	۹۲	۵.۷۴۷

جدول ۱.۳: جاروب بودجه انرژی ثبت شده در results/raw_data/energy/energy_sweep.csv: رفتار سیاست تصادفی و عملکرد سیاست بهینه VI در هر بودجه. سیاست بهینه در همه بودجه‌ها موفقیت 1.0 دارد، اما سیاست تصادفی تقریباً همیشه با اتمام انرژی خاتمه می‌یابد.



شکل ۱.۳: نرخ خاتمهٔ اپیزود با سیاست تصادفی و نرخ موفقیت سیاست بهینهٔ VI در برابر بودجهٔ انرژی. سیاست بهینه در همهٔ بودجه‌ها موفقیت 1.0 دارد، اما سیاست تصادفی تقریباً همیشه با اتمام انرژی خاتمه می‌یابد – نشان می‌دهد محدودیت انرژی برای یک عامل نیاموخته واقعاً سخت‌گیرانه است.

تصمیم نهایی: $\text{max_energy} = 500$. انتخاب بودجه انرژی در این پروژه چند مرحله‌ای بود. در نخستین تلاش، یک مقدار تصادفی برای بودجه برگزیده شد؛ در تلاش دوم کل شبکهٔ آزمایش با $\text{max_energy} = 60$ اجرا شد – بودجه‌ای که از دید سیاست بهینهٔ VI کاملاً قابل‌حل بود (موفقیت 1.0). با این حال، در همان اجرا نرخ موفقیت SARSA نزدیک صفر ماند، که نشان داد معیار «قابل‌حل بودن از دید VI» به‌تنهایی برای موفقیت یادگیرنده‌های نمونه‌محور کافی نیست: با بودجهٔ بسیار تنگ، تقریباً همهٔ اپیزودهای اولیهٔ اکتشافی (با سیاست ϵ -حریصانه) پیش از رسیدن به هر سیگنال پاداش، با اتمام انرژی خاتمه می‌یابند (ستون «خاتمه با اتمام انرژی» بالای 1.00 است) و سیگنال آموزشی برای یادگیری ستاره می‌شود. بنابراین در تلاش بعدی بودجه افزایش یافت تا جایی که به مقدار فعلی یعنی 500 رسید. این افزایش هزینهٔ صریحی نیز دارد: فضای حالت به‌صورت خطی از 39.5k به 325k حالت بزرگ می‌شود که برای بودجهٔ آموزشی ثابت، تعداد بازدید هر حالت را رقیق می‌کند؛ و در بودجهٔ بسیار بزرگ، محدودیت انرژی عملاً چیزی نیست که سیاست آموخته‌شده احساس کند – که با الزام صورت پروژه («تأثیر واقعی، نه صرفاً نمایشی») در تنش است. در نتیجهٔ نهایی، 500 انتخاب شد چون تعادلی است که هم به Q-Learning هم به $\text{SARSA}(\lambda)$ و هم به سناریوهای انتقال یادگیری شانس واقعی رسیدن به نرخ موفقیت غیر صفر می‌دهد؛ این یک انتخاب مصالحه‌ای آگاهانه است، نه مقدار ریاضی بهینه.


فصل ۴

الگوریتم اول: Value Iteration


Value Iteration با استفاده از مدل کامل انتقال و پاداش، بهروزرسانی بلمن زیر را تا همگرایی تکرار می‌کند:

$$V_{k+1}(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V_k(s')]$$


شرط همگرایی بر اساس حداکثر تغییر مقدار در دو تکرار متوالی ($\max |V_{k+1} - V_k|$) با آستانه $\theta = 10^{-6}$ تعریف شده است.



شکل ۱.۴: همگرایی Value Iteration برای سه مقدار γ . با افزایش γ افق مؤثر بلندتر می‌شود و همگرایی کندتر رخ می‌دهد (حدود 83 تکرار برای $\gamma=0.9$ در برابر حدود 101 تکرار برای $\gamma=0.99$).



شکل ۲.۴: تعداد تکرار تا همگرایی و زمان اجرا با افزایش γ رشد آهسته‌ای دارند، اما نرخ موفقیت سیاست حریصانه در هر سه مقدار γ برابر 1.0 است – یعنی γ عمدتاً مقیاس V را تغییر می‌دهد، نه خود سیاست بهینه نهایی.



شکل ۳.۴: نقشه حرارتی V و فلش سیاست حریصانه Value Iteration پیش و پس از دریافت کلید ($k=0$) در برابر $k=1$). سیاست VI به‌عنوان مرجع مقایسه برای دو الگوریتم مدل‌آزاد استفاده می‌شود.

پارامترهای دقیق اجرای VI (از results/raw_data/vi/vi_gamma_sweep.csv و results/models/vi/vi_*.json):

- $\gamma=0.9$: 83 تکرار، حدود 910 ثانیه، موفقیت ارزیابی 1.0
- $\gamma=0.95$: 92 تکرار، حدود 987 ثانیه، موفقیت ارزیابی 1.0
- $\gamma=0.99$: 101 تکرار، حدود 1058 ثانیه، موفقیت ارزیابی 1.0

در هر سه مقدار γ سیاست حریصانه به هدف می‌رسد (میانگین 38.75 گام) و مقدار V در حالت شروع با افزایش γ از 7.47 به 36.63 و سپس 142.97 رشد می‌کند – یعنی γ عمدتاً مقیاس V را تغییر می‌دهد، نه خود سیاست بهینه نهایی.


فصل ۵

الگوریتم دوم: Q-Learning


Q-Learning به صورت off-policy با قاعده بهروزرسانی زیر پیاده‌سازی شده است:

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$


سیاست رفتاری ϵ -greedy است و دو برنامه کاهش ϵ (خطی و نمایی) پیاده‌سازی و مقایسه شده‌اند. مقادیر عددی از default_config.json: $\alpha=0.1$, $\gamma=0.95$, $\epsilon_{start}=1.0$, $\epsilon_{min}=0.01$, افزایش خطی در 5000 اپیزود / نرخ نمایی 0.995 و num_episodes=20000.




شکل ۱.۵: نقشه بازدید Q-Learning (پاداش شکل‌دهی شده، برنامه نمایی) پیش و پس از دریافت کلید. پیش از کلید، بازدیدها به شدت روی مسیر کوتاه به سمت کلید متمرکز است (نوار زرد پررنگ)؛ پس از دریافت کلید، بازدیدها روی چند مسیر جایگزین به سمت هدف پخش می‌شود.



۱۴



شکل ۳.۵: مقایسه منحنی پاداش/تعداد گام بین حالت sparse و shaped (برنامه‌نمایی)، میانگین $\pm$ انحراف معیار سه سید. منحنی shaped بالاتر و پایدارتر از sparse است و به سیاست نهایی قوی‌تری می‌رسد (نرخ موفقیت ارزیابی 0.99 در برابر 0.49).



شکل ۴.۵: مقایسه برنامه کاهش ϵ (خطی در برابر نمایی) برای پاداش sparse. برنامه‌نمایی نخستین موفقیت را زودتر ثبت می‌کند، اما برنامه خطی به سیاست نهایی قوی‌تری می‌رسد (میانگین موفقیت ارزیابی 0.58 در برابر 0.49).

نرخ موفقیت ارزیابی نهایی (میانگین سه سید) و میانگین گام هر ترکیب (shaped/sparse $\times$ خطی/نمایی)، حاصل از بی‌مستقیم مدل‌های ذخیره‌شده 20,000-اپیزودی با خودکد ارزیابی پروژه (results/raw_data/eval_saved_models_summary.csv):

پاداش	برنامه	موفقیت ارزیابی	میانگین گام ارزیابی
sparse	خطی	۵۸.۰	۳۴۲
sparse	نمایی	۴۹.۰	۳۵۴
shaped	خطی	۹۹.۰	۷۵
shaped	نمایی	۷۵.۰	۲۰۵

جدول ۱.۵: موفقیت ارزیابی (گشوده حریصانه، 100 اپیزود) برای هر ترکیب پاداش/برنامه. شکل‌دهی پاداش تأثیر بسیار بزرگی بر کیفیت سیاست نهایی دارد.

۱.۵ بازسازی دستی یک بهروزرسانی واقعی Q

برای راستی‌آزمایی پیاده‌سازی، یک بهروزرسانی واقعی از results/raw_data/q_learning/q_update_trace.csv (اپیزود 2500، گام 0) به‌صورت دستی بازسازی شده است. مقادیر ثبت‌شده در CSV ($\gamma=0.95$, $\alpha=0.1$):

$$s = (1, 1, 0, 500), \quad a = 3, \quad r = -1.0, \quad Q(s, a)_{\text{قبل}} = 4.4491, \quad \max_{a'} Q(s', a') = 5.7306$$

با رابطه Q-Learning:

$$Q(s, a)_{\text{بعد}} = 4.4491 + 0.1[-1.0 + 0.95 \cdot 5.7306 - 4.4491] = 4.4491 + 0.1(-0.00508) = 4.4486$$

که دقیقاً با مقدار ثبت‌شده $q_{\text{after}} = 4.4486$ در فایل مطابقت دارد؛ خطای TD ثبت‌شده نیز -0.0051 است. این بازسازی، صحت هر سه مؤلفه بهروزرسانی (انتخاب $\max_{a'} Q$ ، تنزیل γ و وزن α) را تأیید می‌کند.

فصل ۶


الگوریتم سوم: $SARSA(\lambda)$

یادگیری on-policy همراه با ردپای شایستگی از نوع replacing (نه accumulating) پیاده‌سازی شده است تا از انباشت نامحدود شایستگی هنگام حرکت‌های حلقه‌ای در طول اکتشاف جلوگیری شود:


$$\delta_t = r_{t+1} + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t), \quad Q \leftarrow Q + \alpha \delta_t E$$

$$E_t(s, a) = \gamma \lambda E_{t-1}(s, a) + \mathbf{1}\{s=s_t, a=a_t\} \quad (\text{در بازدید مجدد با محدودسازی به } \lambda)$$

مقدار λ روی $\{0, 0.3, 0.7, 0.9\}$ آزمایش شده است. وقتی $\lambda=0$ ، الگوریتم عملاً به SARSA یک‌مرحله‌ای تقلیل می‌یابد چون تنها همان یک زوج (s_t, a_t) شایستگی غیر صفر دارد؛ با افزایش λ ، خطای TD به‌صورت وزن‌دار به حالت/عمل‌های چند گام قبل نیز پس‌انتشار می‌یابد.




شکل ۱.۶: چپ: خطای TD (δ) طی یک اپیزود نمونه (اپیزود 10). راست: افت نمایی ردپای شایستگی (E ، مقیاس لگاریتمی) برای چند زوج حالت-عمل؛ نقاط اوج مجدد نشان‌دهنده بازدید دوباره همان زوج و بازنشانی شایستگی (رفتار replacing) است.




شکل ۲.۶: نقشه بازدید SARSA ($\lambda=0$) (پاداش شکل‌دهی شده) پیش و پس از کلید. در مقایسه با Q-Learning (شکل ۱.۵) پراکندگی بازدیدها بیشتر و کمتر متمرکز روی یک مسیر باریک است – سازگار با رفتار محتاطانه‌تر on-policy در برابر ریسک اکتشاف.

۱.۶ نکته حسابرسی: عدم‌تقارن حالت پاداش

پیش از SARSA در ابتدا فقط با `reward_mode=sparse` آموزش می‌دید (فیلد مفرد `experiment_grid.sarsa_lambda.reward_mode`). شبکه Q-Learning هر دو حالت `sparse` و `shaped` را آموزش می‌داد (فهرست `experiment_grid.q_learning.reward_modes`). تنظیمات اکنون اصلاح شده و `experiment_grid.sarsa_lambda.reward_modes` شامل `["sparse", "shaped"]` است (ر.ک. `experiments/configs/default_config.json`). مدل‌های ذخیره‌شده فعلی SARSA هر دو حالت پاداش را پوشش می‌دهند، اما تنها یک اجرای کوتاه ۵۰-اپیزودی (`dry-run`) هستند و در ارزیابی حریصانه ۱۰۰ اپیزود روی هر چهار مقدار λ و هر دو حالت پاداش، موفقیت صفر ثبت می‌کنند (همگی با `mean_steps = 500`، یعنی سقف گام). بنابراین هیچ نتیجه‌گیری کمی درباره موفقیت نهایی SARSA از این مدل‌ها ممکن نیست؛ داده قابل استناد فقط برای تحلیل رفتار (ردپای شایستگی، نقشه بازدید و پایداری اواخر آموزش) معتبر است.



شکل ۳.۶: مقایسه نرخ پاداش/گام برای SARSA ($\lambda=0.3$): `sparse` در برابر `shaped` (پس از اصلاح شبکه آزمایش).



شکل ۴.۶: جاروب λ برای پاداش sparse (سه سید). پایداری اواخر آموزش تقریباً مستقل از λ است (انحراف معیار بازگشت در 1000 اپیزود آخر: 155.2، 156.5، 157.2، 156.8 برای $\lambda=0, 0.3, 0.7, 0.9$) و نرخ موفقیت ارزیابی برای هر چهار مقدار برابر صفر است – نتیجه مدل‌های کوتاه 50-اپیزودی، (dry-run) نه شکست خود ردپای شایستگی.

بهترین تعادل λ : چون مدل‌های ذخیره‌شده SARSA تنها یک اجرای 50-اپیزودی هستند و در ارزیابی، موفقیت صفر دارند، از داده کمی موجود نمی‌توان نتیجه‌گیری قطعی درباره بهترین λ تحت پاداش shaped ارائه داد. تحلیل کیفی ردپای شایستگی نشان می‌دهد افزایش λ بدون افزایش بازده نهایی، بازگشت اواخر آموزش را در مرز 500 گام نگه می‌دارد؛ بنابراین مقدار میانه $\lambda=0.3$ برای ادامه کار (اجرای بلندمدت) پیشنهاد می‌شود.

فصل ۷

مقایسه سه الگوریتم

هر سه الگوریتم روی یک نقشه و یک تعریف پاداش یکسان (sparse، به عنوان reference_reward_mode) مقایسه شده‌اند.


۱.۷ اصلاح یک باگ انصاف در انتخاب بهترین مدل

توابع pick_best_sarsa_variant و pick_best_ql_variant در ابتدا هر ترکیبی از (reward_mode, schedule/ λ) را که بیشترین eval_success_rate داشت انتخاب می‌کردند – که پس از افزوده شدن اجراهای shaped، به‌طور خاموش شکل‌دهی شده Q-Learning را در برابر SARSA/VI به‌صورت sparse مقایسه می‌کرد و الزام «تعریف پاداش یکسان» صورت پروژه را نقض می‌کرد. هر دو تابع اکنون پیش از رتبه‌بندی، انتخاب را به reference_reward_mode محدود می‌کنند.

معیار	Value Iteration	Q-Learning	SARSA(λ)
نوع روش	مدل محور	مدل آزاد، off-policy	مدل آزاد، on-policy
واحد پیشرفت	تکرار بلمن	اپیزود	اپیزود
خروجی اصلی	V و سیاست	Q و سیاست	E، Q و سیاست
معیار اجباری مقایسه	زمان و همگرایی	نمونه، پاداش، پایداری	اثر λ و رفتار ایمن
نرخ موفقیت ارزیابی*	1.0	0.58	0.0


جدول ۱.۷: جدول مقایسه سه الگوریتم. *مقادیر SARSA/Q-Learning در reference_reward_mode=sparse و پس از اصلاح باگ انتخاب بهترین مدل (منبع: comparison_summary.csv، eval_saved_models_summary.csv). برای Q-Learning بهترین ترکیب (برنامه خطی) میانگین سه سید $\frac{0.59+0.51+0.64}{3} = 0.58$ داده است؛ مقدار SARSA مربوط به مدل های کوتاه 50-اپیزودی (dry-run) است و صفر آن به معنای اثبات شکست الگوریتم نیست.

Learned policy per algorithm — arrows = greedy action, shade = own V / max-Q at most-visited energy



شکل ۱.۷: سیاست آموخته‌شده هر الگوریتم (فلش = عمل حریصانه، رنگ = مقدار $\max\text{-}Q/V$ خود الگوریتم در پرتکرارترین سطح انرژی بازدیدشده). سیاست Value Iteration هر خانه معتبر را پوشش می‌دهد؛ Q-Learning تقریباً تمام حالت‌های معتبر را (264/266 در حالت دارای کلید) پوشش داده، اما SARSA پوشش کمتری دارد (173–230/266 بسته به مدل/سید) که با ماهیت محتاطانه‌تر اکتشاف on-policy سازگار است.

Agent policy vs. VI agreement (share of visited energy levels)



شکل ۲.۷: درصد توافق عمل حریصانه SARSA/Q-Learning با سیاست مرجع Value Iteration در هر خانه (سبز = همیشه همراستا، قرمز = هرگز همراستا). در میان حالت‌های بازدیدشده، نرخ توافق عمل با VI برای Q-Learning $\approx 32.2\%$ و برای SARSA $\approx 21.9\%$ است (comparison_summary.csv). Q-Learning به‌طور کلی توافق بالاتر و یکنواخت‌تری نسبت به SARSA نشان می‌دهد؛ خانه‌های سفید یعنی آن حالت اصلاً بازدید نشده است.

۲.۷ سه حالت نمونه اختلاف سیاست

مختصات دقیق سه حالت نمونه از comparison_sample_states.csv استخراج شده‌اند (ستون vi_action عمل سیاست مرجع VI و agent_action عمل حریصانه عامل مدل آزاد است):

- **بزرگ‌ترین شکاف عمل (Q-Learning):** حالت (4, 15, 14) (دارای کلید، انرژی ۴) – عمل VI=۱ در برابر عمل عامل=۲ با شکاف action_gap = 114.0. این خانه نزدیک هدف با انرژی کم است و کوچک‌ترین خطای ارزش‌گذاری به عملی کاملاً متفاوت می‌انجامد.

- کوچک‌ترین شکاف غیرصفر (Q-Learning): حالت (13, 6, 1, 12) با شکاف 1.83×10^{-6} – دو عمل عملاً هم‌ارزند و اختلاف سیاست در اینجا فقط به نویز عددی برمی‌گردد.
- نزدیک خانه جریمه (Q-Learning): حالت (7, 6, 1, 471) (عمل VI=۳ در برابر عامل=۲، شکاف 11.9)؛ برای SARSA هم‌تا آن (2, 6, 0, 61) است (عمل VI=۲ در برابر عامل=۱). این حالات نشان می‌دهند اختلاف واقعی تصمیم در جایی رخ می‌دهد که یک گزینه دور زدن خانه جریمه در برابر عبور نزدیک آن قرار دارد – سازگار با پاسخ پرسش 2.


فصل ۸

بخش انتقال یادگیری

این بخش فقط روی Q-Learning (نسخه پاداش شکل‌دهی‌شده) انجام شده است. عامل ابتدا در محیط مبدأ آموزش دیده و جدول Q آن ذخیره شده؛ سپس دو محیط مقصد ساخته شده‌اند: **مشابه** (حدود 15–20% موانع جابه‌جا شده، شروع/کلید/هدف ثابت) و **متفاوت** (حداقل 35% موانع تغییر کرده، محل کلید یا هدف جابه‌جا شده و چند خانه جریمه جدید افزوده شده است). هر دو نقشه با BFS از نظر وجود مسیر معتبر اعتبارسنجی شده‌اند.

چهار سناریو آزمایش شده است: آموزش از صفر (خط مبنا)، انتقال کامل، انتقال تعدیل‌شده با ضریب $\beta \in \{0.25, 0.5, 0.75\}$ و انتقال انتخابی (فقط حالت‌هایی که همسایگی محلی آن‌ها تغییر نکرده است):


$$Q_T^{(0)}(s, a) = \beta Q_S(s, a)$$




شکل ۸.۱: مسیر حریصانه در نقشه مبدأ (72 گام) در برابر نقشه مقصد مشابه پس از انتقال کامل (60 گام) – انتقال روی هدف مشترک به مسیری کوتاه‌تر رسیده است.




شکل ۲.۸: مسیر حریصانه در نقشه مبدأ (72 گام) در برابر نقشه مقصد متفاوت پس از انتقال کامل (68 گام). با وجود جابه‌جایی هدف/موانع، عامل همچنان به هدف رسیده است، اما مسیر آموخته‌شده حلقه‌های اضافی (دور زدن‌های تکراری نزدیک کلید) دارد که نشانه سازگاری ناقص دانش منتقل‌شده با ساختار جدید است.



شکل ۳.۸: عملکرد آموزش روی نقشه مشابه: تمام سناریوهای انتقال (full، scaled_0.25/0.5/0.75) بازگشت شروع (jumpstart) نزدیک به صفر دارند در برابر حدود 1330- برای آموزش از صفر و حدود 1020- برای انتقال انتخابی – انتقال کامل بهترین شروع را می‌دهد و منحنی یادگیری عملاً از همان ابتدا نزدیک به سیاست همگراست.



شکل ۴.۸: عملکرد آموزش روی نقشه متفاوت: مزیت انتقال بسیار کوچکتر است (jumpstart حدود 1100- تا 1200- برای scaled/full در برابر حدود 1400- برای آموزش از صفر) و جالب اینکه انتقال انتخابی (حدود 1360-) عملاً هیچ مزیت معناداری نسبت به آموزش از صفر ندارد – چون معیار «همسایگی محلی بدون تغییر» وقتی +35% نقشه عوض شده، تعداد بسیار کمی حالت را واجد شرایط انتقال می‌کند.



شکل ۵.۸: اختلاف قدرمطلق max-Q پیش و پس از انتقال (مبدأ شکل‌دهی شده → مقصد متفاوت/کامل)، در سطح انرژی حداکثر. در حالت بدون کلید (چپ) تغییرات تقریباً ناچیز و پراکنده‌اند؛ اما در حالت دارای کلید (راست) تقریباً کل نقشه اختلاف کوچک ولی سیستماتیک نشان می‌دهد – سازگار با این واقعیت که هدف/کلید در نقشه متفاوت جابه‌جا شده و بنابراین دقیقاً بخش پس‌از-کلید سیاست است که باید بازآموزی شود.

۱.۸ یک نمونه انتقال منفی

طبق الزام صورت پروژه، حداقل یک نمونه انتقال منفی باید مستند شود که در آن دانش منتقل شده عامل را به عمل نامناسب هدایت کرده است. نمونه مستندشده در negative_transfer_case.json و negative_transfer_checkpoints.csv:

• محیط مقصد متفاوت: موقعیت کلید از (6, 6) به (6, 2) منتقل شده و مدل مبدأ `q_learning_shaped_exponential_seed8565.json` منتقل شده است.

• حالت (2, 1, 6, 8) (دارای کلید، انرژی ۲، در دو گامی کلید قدیم): سیاست مرجع VI عمل 3 (سمت کلید جدید) را انتخاب می‌کند اما عامل منتقل شده تا episode 5000 عمل 0 را انتخاب می‌کند (`matches_vi=False`) در همه نقاط کنترل؛ شکاف عمل `action_gap=147.7` و کل سطر Q این حالت صفر است.


• ریشه: این حالت در آموزش مبدأ به‌ندرت بازدید شده (مسیر آموخته شده به سمت کلید قدیم در (6, 6) می‌رفت) و پس از انتقال، جدول Q آن هنوز صفر است؛ یعنی دانش منتقل شده در این ناحیه نه فقط بی‌فایده که گمراه کننده نیست، بلکه غایب است. این یک نمونه انتقال منفی به شکل «کمک نکردن» است نه «هدایت به اشتباه فعال» – عامل در آن نقطه صرفاً راهنمایی از دانش مبدأ دریافت نمی‌کند و باید خودش آن ناحیه را بازآموزی کند.

فصل ۹


رابط گرافیکی


رابط گرافیکی با customtkinter در gui/app.py پیاده‌سازی شده و حرکت عامل را مرحله‌به‌مرحله نمایش می‌دهد. دیوارها، خانه عادی، خانه جریمه، کلید، در، هدف، عامل و نشانگر انرژی هر یک نشانه بصری متمایز دارند. کنترل‌ها شامل انتخاب الگوریتم/محیط، شروع/توقف/ادامه/بازنشانی، کنترل سرعت انیمیشن، و نمایش لحظه‌ای شماره آپیزود، گام، پاداش، ϵ ، وضعیت کلید و نرخ موفقیت اخیر است.

نکته رفتاری (نه باگ): در در نقشه مبدأ صرفاً یک گلوگاه فیزیکی جدا از کلید نیست – رسیدن به خانه هدف فقط زمانی برد محسوب می‌شود که `has_key==1` باشد. از آنجا که V/Q به‌ازای کل حالت $(r, c, has_key, energy)$ ذخیره می‌شوند، عمل بهینه در همان خانه پیش و پس از دریافت کلید می‌تواند به‌طور مشروط متفاوت باشد. آنچه پوشش سیاست در رابط گرافیکی پس از دریافت کلید نشان می‌دهد، صرفاً برش `has_key=1` همان جدول است، نه یک سیاست بازآمخته یا خراب. خانه‌های خالی در پوشش، حالت‌هایی هستند که به‌ندرت یا هرگز در آموزش بازدید شده‌اند (سطر Q آن‌ها هرگز از صفر خارج نشده)، نه خطایی در منطق برش `(_slice_has_key_energy / _load_policy_grid, gui/app.py)`.
عکس‌های ثابت از رابط:




شکل ۱.۹: رابط گرافیکی در حین ارزیابی سیاست VI.

شکل ۲.۹: نمایش روی هم‌گذاری سیاست VI روی نقشه (پوشش سیاست برش $has_key=1$).



شکل ۳.۹: رابط گرافیکی در حین ارزیابی Q-Learning.



شکل ۴.۹: رابط گرافیکی در حین ارزیابی SARSA.

فصل ۱۰

پرسش‌های تحلیلی

۱.۱۰ پرسش ۱ – تعریف MDP و حفظ خاصیت مارکوف

فضای حالت $s = (r, c, \text{has_key}, \text{energy})$ ، فضای عمل چهار جهت اصلی، تابع انتقال تصادفی با احتمال $0.8/0.1/0.1$ ، دو تابع پاداش (shaped/sparse)، ضریب تنزیل $\gamma \in \{0.9, 0.95, 0.99\}$ برای VI و مقادیر جداگانه برای Q-SARSA/Learning (هر دو $\gamma=0.95$ ، $\alpha=0.1$)، و حالت‌های پایانی «رسیدن به هدف با کلید»، «اتمام انرژی» و «عبور از سقف گام». چون احتمال گام بعد و پاداش آن تنها به $(r, c, \text{has_key}, \text{energy})$ فعلی و عمل بستگی دارد – نه به اینکه عامل چگونه به این حالت رسیده – خاصیت مارکوف حفظ می‌شود؛ اگر has_key یا energy از حالت حذف می‌شدند، نتیجه گام بعد (باز بودن در، یا خاتمه اییزود) دیگر از روی حالت به‌تنهایی قابل پیش‌بینی نبود.

۲.۱۰ پرسش ۲ – تفاوت on-policy و off-policy نزدیک خطر

Q-Learning در به‌روزرسانی خود از $\max_{a'} Q(s', a')$ استفاده می‌کند؛ یعنی مقدار حالت بعد را طبق بهترین عمل ممکن تخمین می‌زند، صرف‌نظر از اینکه سیاست رفتاری واقعی (ϵ -greedy) چقدر احتمال دارد واقعاً همان عمل بهینه را انتخاب کند. SARSA در عوض از $Q(s_{t+1}, a_{t+1})$ – یعنی عملی که واقعاً طبق سیاست رفتاری در گام بعد انتخاب شده – استفاده می‌کند. نزدیک خانه‌های جریمه، این تفاوت به‌صورت مستقیم در نقشه بازدید قابل مشاهده است: Q-Learning (شکل ۱.۵) مسیریابی باریک و نزدیک به خانه‌های جریمه را با اطمینان بیشتری دنبال می‌کند چون ارزیابی آن فرض می‌کند در آینده همیشه بهینه عمل خواهد شد، در حالی‌که SARSA (شکل ۲.۶) پراکندگی بیشتری نشان می‌دهد که سازگار با محاسبه ریسک واقعی گام تصادفی/اکتشافی به داخل خانه جریمه است – یعنی سیاست SARSA در عمل محتاطانه‌تر (شبیه پدیده کلاسیک cliff-walking) می‌شود.

۳.۱۰ پرسش ۳ – نیاز VI به مدل انتقال

Value Iteration برای محاسبه انتظار $\sum_{s'} P(s' | s, a)[\dots]$ باید دقیقاً بداند با چه احتمالی هر عمل به کدام حالت بعد می‌انجامد؛ این مدل به‌صورت تحلیلی در دسترس است چون خود نویسنده محیط آن را می‌داند (احتمال 0.8/0.1/0.1). Q-Learning و SARSA این احتمالات را هرگز مستقیماً نمی‌بینند؛ آن‌ها فقط از نمونه‌های واقعی تجربه‌شده (s, a, r, s') یاد می‌گیرند. مزیت VI در این پروژه: با مدل کامل، در تعداد تکرار کم (حدود 80–100) به سیاست دقیقاً بهینه با موفقیت 1.0 می‌رسد. محدودیت آن: در دنیای واقعی مدل انتقال معمولاً در دسترس نیست و محاسبه با فضای حالت 325k-تایی (در بودجه انرژی 500) پرهزینه می‌شود. مزیت مدل‌آزادها: نیازی به دانستن دینامیک محیط ندارند و مستقیماً از تعامل یاد می‌گیرند؛ محدودیت آن‌ها: نیاز به تعداد قابل‌توجه اپیزود برای همگرایی و پوشش ناقص‌تر فضای حالت (به‌ویژه SARSA، با حدود 65–86% پوشش در برابر 99% برای Q-Learning).

۴.۱۰ پرسش ۴ – بهترین تعادل λ

با شواهد عددی موجود (شکل ۴.۶): در حالت پاداش sparse، پایداری اواخر آموزش تقریباً مستقل از λ است (انحراف معیار بازگشت بین 155.2 تا 157.2، بدون روند یکنواخت) و نرخ موفقیت ارزیابی برای هر چهار مقدار صفر است – که نتیجه مدل‌های کوتاه 50-اپیزودی (dry-run) است، نه شکست خود λ . تحلیل کیفی ردپای شایستگی نشان می‌دهد $\lambda=0.3$ تعادل معقولی بین سرعت انتشار اعتبار و پایداری برقرار می‌کند: به‌اندازه کافی بزرگ است که چند گام آخر مسیر موفق را تقویت کند، اما نه چندان بزرگ که نویز اکتشاف اولیه را تا خیلی عقب‌تر پس‌انتشار دهد. نتیجه‌گیری قطعی برای حالت shaped منوط به اجرای بلندمدت جاروب λ تحت آن حالت است (مدل‌های فعلی فقط dry-run هستند).

۵.۱۰ پرسش ۵ – سه حالت اختلاف سیاست مدل‌آزاد در برابر VI

ر.ک. بخش «سه حالت نمونه اختلاف سیاست» در فصل مقایسه؛ خلاصه: (۱) خانه‌های روی یک مسیر جایگزین هم‌تراز به سمت کلید، (۲) خانه‌های مجاور در که تصمیم بین مسیر مستقیم و دور زدن جریحه را می‌سازند، و (۳) خانه‌های کم‌بازدید در گوشه‌های دور از مسیر اصلی که علت اختلاف در آن‌ها عدم همگرایی است نه انتخاب واقعی متفاوت.

۶.۱۰ پرسش ۶ – محیط مشابه در برابر متفاوت در انتقال

روی نقشه مشابه، انتقال (به‌ویژه کامل) عملکرد آغازین را تقریباً به سطح سیاست همگرا می‌رساند (jumpstart نزدیک صفر در برابر 1330- برای آموزش از صفر)، سرعت یادگیری را به‌شدت افزایش می‌دهد و عملکرد نهایی تقریباً یکسان با آموزش از صفر همگرا می‌شود. روی نقشه متفاوت، مزیت انتقال به‌طور محسوس کوچک‌تر است (jumpstart حدود 1100- تا 1200- در برابر 1400- برای آموزش از صفر) و انتقال انتخابی عملاً هیچ مزیت معناداری نمی‌دهد چون معیار «همسایگی محلی بدون تغییر» با +35% تغییر نقشه تقریباً هیچ حالتی را واجد شرایط نمی‌کند. علاوه بر این، نقشه

اختلاف Q (شکل ۵.۸) نشان می‌دهد بیشترین نیاز به بازنویسی دانش دقیقاً در بخش پس‌از-کلید سیاست است – که مستقیماً با جابه‌جایی هدف/کلید در نقشه متفاوت همخوانی دارد. این تمایز با جمله کلی و بدون شاهد مانند «انتقال خوب بود» فرق دارد: در محیط مشابه انتقال با شواهد عددی روشن سودمند است؛ در محیط متفاوت سودمندی محدود و مشروط است.

فصل ۱۱

استفاده از منابع و هوش مصنوعی

دستیارهای هوش مصنوعی در طول پروژه برای پیاده‌سازی، اشکال‌زدایی، رسم نمودار و پیش‌نویس اسکرپت‌ها/مستندات استفاده شده‌اند. تمام اعداد ذکر شده در این گزارش از فایل‌های واقعی زیر results/ تولید شده‌اند، نه تایپ شده دستی.

مورد استفاده	پیشنهاد	ناقص/نادرست	هوش	اصلاح دانشجو	دلیل
موفقیت نزدیک صفر	فقط max_energy را دو برابر کن			علت واقعی تشخیص داده شد: دو برابر کردن انرژی	
SARSA	«(60→100)»			شبکه آزمایش sarsa_lambda	توضیحی برای شکست
				فقط reward_mode=sparse	کامل ($\lambda=0.9$) نمی‌دهد؛
				را آموزش می‌داد در حالی که	عدم تقارن پاداش آن را
				q_learning هر دو حالت را	توضیح می‌دهد
				می‌دید؛ جاروب shaped اضافه شد	
				و بودجه انرژی به صورت مستقل	
				و بر اساس جاروب انرژی به	
				max_energy=500 رسید (فصل	
				(۳)	
انتخاب «بهترین»	انتخاب هر ترکیب (re-			انتخاب	به نسخه بی‌قید به‌طور
مدل بین‌الگوریتمی	ward_mode, schedule/ با			reference_reward_mode	خاموش Q-Learning
	eval_success_rate بالاترین			(sparse) محدود شد، در هر دو	شکل‌دهی شده را در
				تابع pick_best_ql_variant و	برابر SARSA/VI
				pick_best_sarsa_variant	شکل‌دهی نشده مقایسه
					می‌کرد؛ الزام «پاداش
					یکسان» را نقض می‌کرد
پوشش سیاست یک	خواندن سیاست حریصانه فقط در		برش	بر اساس	پس از اولین گام، انرژی
فلش	energy = max_energy		(has_key, energy)	فعلی	دیگر هرگز برابر
				عامل، با بازگشت به پربازدیدترین	max_energy نیست؛
				سطح انرژی برای مدل‌های	برش قدیمی پوششی تقریباً
				ذخیره شده	خالی نشان می‌داد

جدول ۱.۱: جدول کوتاه افشای استفاده از هوش مصنوعی (نسخه کامل در README.md مخزن پروژه موجود است).